3. Matriz de costos y decisión de modelo

Especialización en IA Automation - CoderHouse | Gerónimo Pastori | Octubre 2026

Decisión

El nodo de IA usa openai/gpt-oss-120b en Groq. La decisión se tomó por recomendación de los docentes de la especialización y porque las APIs de OpenAI y Anthropic son de pago, mientras que Groq ofrece un plan gratuito que permite construir y probar el proyecto completo. Se pide que la corrección tenga en cuenta esta condición. El nombre es Groq (el proveedor de inferencia), no Grok de xAI.

La matriz compara el modelo usado con las alternativas que se habrían elegido sin esa restricción, para mostrar qué cambiaría en costo al escalar.

Precios vigentes (USD por millón de tokens)

Modelo	Entrada	Salida	Batch (-50%)	Caché de entrada	Fuente
Groq - openai/gpt-oss-120b (usado)	0,15	0,60	0,075 / 0,30	No aplica	morphllm.com/groq-pricing (13/10/2026)
OpenAI - GPT-4o mini	0,15	0,60	0,075 / 0,30 (*)	0,075	developers.openai.com/docs/models/gpt-4o-mini
Anthropic - Claude Haiku 4.5	1,00	5,00	0,50 / 2,50	Lectura 0,10; escritura 1,25 (5 min) o 2,00 (1 h)	platform.claude.com/docs/about-claude/pricing

(*) La página de OpenAI consultada no mostraba el valor del precio Batch; el 50 % es el descuento publicado de su Batch API y debe verificarse antes de contratar. El precio de Groq es de un sitio de seguimiento de precios, no de la página oficial de Groq. Verificar en la consola antes de depender de esa cifra.

Supuestos de volumen

Por pieza generada: unos 900 tokens de entrada (prompt fijo, contexto RAG de 7 registros e idea semilla) y unos 800 de salida (tope de 1024). Son estimaciones del diseño, no mediciones: el consumo real se puede leer en el detalle de cada corrida de Make y en el panel de uso de Groq. Escenario: 1.000 piezas por mes.

Costo mensual estimado (1.000 piezas)

Alternativa	Entrada	Salida	Total síncrono	Total con Batch
Groq gpt-oss-120b	$0,135	$0,48	$0,62	$0,31
OpenAI GPT-4o mini	$0,135	$0,48	$0,62	$0,31 (*)
Claude Haiku 4.5	$0,90	$4,00	$4,90	$2,45

Con 1.000 piezas por mes, la diferencia entre Groq y GPT-4o mini es mínima; Haiku cuesta unas ocho veces más por la salida. En el plan gratuito de Groq el costo del proyecto es cero y el límite pasa a ser el de tokens por minuto, que ya se alcanzó durante las pruebas con otros modelos.

Matriz de decisión por tarea

La primera fila es lo que está implementado. Las demás son el diseño recomendado si el sistema creciera, y los volúmenes y tamaños de texto son supuestos, no mediciones. Todos los precios son los de la tabla anterior.

Tarea	Estado	Modelo y modo	Supuesto por tarea	Costo por 1.000	Por qué
Redactar el post a partir de idea y contexto RAG	Implementada	Groq gpt-oss-120b, síncrono	900 entrada / 800 salida	$0,62	Tarea de generación corta; precio bajo y la revisión humana corrige el resultado.
Clasificar o etiquetar ideas (tema, tono, prioridad)	Propuesta	GPT-4o mini, síncrono	300 entrada / 50 salida	$0,08	Tarea mecánica y de salida corta: no justifica un modelo caro.
Leer y resumir informes largos (20 páginas)	Propuesta	Claude Haiku 4.5, síncrono	15.000 entrada / 600 salida	$18,00	Lectura densa. Cuesta 7 veces más que GPT-4o mini ($2,61 por 1.000) y solo se justifica si una prueba de calidad lo confirma; esa prueba no se hizo.
Reprocesar el archivo histórico (10.000 piezas)	Propuesta	Groq gpt-oss-120b con Batch	900 entrada / 800 salida	$0,31 (10.000: $3,08)	Proceso masivo y sin urgencia: 24 h de espera a cambio de la mitad del precio.

Ahorro estimado con Batch en el proceso masivo: sobre las 10.000 piezas, pasar de $6,15 en modo síncrono a $3,08 en lote ahorra $3,08, que es el 50 % anunciado por los proveedores. Con Claude Haiku 4.5 el mismo proceso pasaría de $49,00 a $24,50. El ahorro es el descuento de lista aplicado a mis supuestos; no se midió en una corrida real de Batch. En el caso de lectura densa, si varias consultas reutilizaran el mismo informe de más de 4.096 tokens, el caché de Claude (lectura a $0,10 por millón contra $1,00 de entrada) bajaría el costo de esa parte en un 90 %.

Batch API (descuento del 50 %)

Batch procesa pedidos de forma asíncrona, con una ventana de entre 24 horas y 7 días, a la mitad del precio. En este proyecto no se usa por dos motivos: el módulo de Groq en Make hace llamadas síncronas y no expone Batch, y la persona espera el borrador para revisarlo en el día. Se usaría si el volumen creciera a miles de piezas por mes y se aceptara que el borrador llegue al día siguiente, por ejemplo con un escenario nocturno que cargue todas las ideas pendientes en un lote. Ahí el ahorro sería del 50 % sobre la columna "Total síncrono".

Caché de prompt

La parte fija del prompt (instrucción de sistema más contexto RAG) mide unos 750 tokens. El caché de Claude Haiku 4.5 exige un mínimo de 4.096 tokens y el automático de OpenAI, 1.024, así que con este prompt no se activaría en ninguno. Se justificaría si la base RAG creciera por encima de esos umbrales.

Control de gasto implementado

- max_tokens limitado a 1024 en el módulo de IA.
- Se usan 7 registros RAG atómicos en vez de documentos largos; la búsqueda trae como máximo 10.
- Los filtros del Router evitan generar dos veces la misma pieza, de modo que no se pagan llamadas repetidas.
- El Break reintenta como máximo 3 veces con 5 minutos de espera, para no entrar en un ciclo de llamadas que fallan.

Criterio de elección

Para este caso de uso (posts cortos de LinkedIn con tono definido por contexto), un modelo de la clase de gpt-oss-120b o GPT-4o mini alcanza. Haiku 4.5 se justificaría si la calidad de redacción en español neutral fuera insuficiente; hasta ahora no se hizo una evaluación comparativa de calidad, solo de costo.